

MANUEL PROFESSIONNEL ET AVANCÉ

Consultant en innovation technologique, transformation numérique, cybersécurité, intelligence artificielle, développement logiciel et stratégie digitale.

DATA SCIENCE

Contact	Coordonnées
Site web	www.charmantnyungu.com
Email	consultant@charmantnyungu.com
Téléphone	+243 835 137 837
Édition	Formation complète — 2026

Charmant Nyungu

Vision du cours



Ce manuel forme à l'analyse, à la modélisation, à l'intelligence artificielle appliquée et à la livraison de projets data fiables.

Présentation du manuel

Ce manuel forme à la Data Science et à l'Intelligence Artificielle avancée. Il accompagne l'apprenant depuis les statistiques jusqu'aux systèmes modernes : Pandas, visualisation, machine learning, deep learning, NLP, computer vision et projets professionnels. L'approche privilégie la compréhension, l'expérimentation, l'évaluation rigoureuse et l'impact métier.

L'auteur, Charmant Nyungu, propose une formation structurée pour les étudiants, développeurs, chercheurs, analystes, entrepreneurs et professionnels qui veulent transformer des données en décisions et des modèles en produits fiables.

Élément	Détail
Auteur	Charmant Nyungu
Profession	Consultant en innovation technologique, transformation numérique, cybersécurité, intelligence artificielle, développement logiciel et
Site	www.charmantnyungu.com
Email	consultant@charmantnyungu.com
Téléphone	+243 835 137 837

Préface

La Data Science n'est pas seulement une collection de bibliothèques. C'est une discipline de raisonnement : poser une bonne question, comprendre les données, mesurer l'incertitude, tester les hypothèses, construire un modèle et expliquer clairement ses limites.

Comment utiliser ce livre

- Reproduire chaque exemple dans un notebook ou un script Python.
- Créer un jeu de données personnel pour chaque chapitre.
- Comparer les métriques plutôt que chercher un score isolé.
- Documenter les hypothèses, les biais, les limites et les risques.
- Transformer les exercices en mini projets de portfolio.

Table des matières détaillée

1. Partie 1 : Fondations statistiques

- Logique statistique : population, échantillon, variable, biais
- Statistiques descriptives : moyenne, médiane, variance, écart-type
- Probabilités appliquées : distribution, incertitude, loi normale, décision

- Tests statistiques : hypothèse, p-value, intervalle, erreur

2. Partie 2 : Pandas et préparation des données

- DataFrame professionnel : lecture, colonnes, types, index
- Nettoyage des données : valeurs manquantes, doublons, formats, outliers
- Transformation et agrégation : groupby, merge, pivot, features
- Qualité et gouvernance data : traçabilité, dictionnaire, validation, documentation

3. Partie 3 : Visualisation et storytelling

- Matplotlib et Seaborn : histogramme, courbe, boxplot, heatmap
- Plotly et dashboards : interaction, filtre, KPI, exploration
- Communication data : message, contexte, comparaison, limites

4. Partie 4 : Machine Learning

- Régression : variables, erreur, régularisation, interprétation
- Classification : classes, précision, rappel, matrice de confusion
- Clustering : distance, segments, KMeans, profilage
- Évaluation des modèles : train-test, cross-validation, métriques, surapprentissage
- Feature engineering : encodage, normalisation, sélection, pipeline

5. Partie 5 : Deep Learning

- Réseaux neuronaux : neurone, couche, activation, perte
- TensorFlow et Keras : modèle, entraînement, callbacks, sauvegarde
- PyTorch : tensor, autograd, module, training loop
- MLOps pour deep learning : versioning, monitoring, drift, déploiement

6. Partie 6 : NLP

- Traitement du texte : tokenisation, nettoyage, lemmatisation, n-grammes
- Classification de texte : sentiment, spam, support client, évaluation
- Embeddings et transformers : vecteurs, attention, fine-tuning, limites
- Applications africaines du NLP : langues locales, administration, éducation, service client

7. Partie 7 : Computer Vision

- Bases de l'image numérique : pixels, canaux, filtres, prétraitement
- Classification d'images : CNN, augmentation, validation, erreurs
- Détection et segmentation : objets, masques, annotation, métriques
- Cas santé, sécurité et agriculture : imagerie, surveillance, cultures, éthique

8. Partie 8 : Projets professionnels

- Scoring bancaire : risque, features, modèle, explicabilité
- Prévision santé publique : séries, épidémiologie, alertes, tableau de bord
- Recommandation e-commerce : historique, similarité, ranking, évaluation
- Assistant IA métier : données, contexte, réponse, sécurité
- Vision intelligente : caméra, classification, alerte, audit

9. Partie 9 : Exercices, certification et annexes

- Banque d'exercices : statistiques, Pandas, ML, IA
- Examens blancs : questions, cas, projet, soutenance
- Glossaire et feuilles de route : termes, références, progression, spécialisation

Logique statistique

Ce chapitre traite de logique statistique avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Pipeline data science



Objectifs pédagogiques

- Comprendre le rôle de logique statistique dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
population	Comment utiliser population pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
échantillon	Comment utiliser échantillon pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
variable	Comment utiliser variable pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
biais	Comment utiliser biais pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.


Explication approfondie

population

population est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. population contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

échantillon

échantillon est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. échantillon contribue à rendre cette enquête plus rigoureuse.

variable

variable est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. variable contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

biais

biais est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. biais contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Logique statistique

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser logique statistique pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à population. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à échantillon. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à variable. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à biais. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à population. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Statistiques descriptives

Ce chapitre traite de statistiques descriptives avec une approche professionnelle. L’objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l’analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de statistiques descriptives dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
moyenne	Comment utiliser moyenne pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
médiane	Comment utiliser médiane pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
variance	Comment utiliser variance pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
écart-type	Comment utiliser écart-type pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

moyenne

moyenne est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d’obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l’incertitude et traduire l’analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. moyenne contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences



Pandas



Stats



ML



DL



NLP



Vision

médiane

médiane est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.


Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. médiane contribue à rendre cette enquête plus rigoureuse.

variance

variance est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. variance contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning



écart-type

écart-type est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. écart-type contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Statistiques descriptives

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser statistiques descriptives pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à moyenne. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à médiane. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à variance. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à écart-type. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à moyenne. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Probabilités appliquées

Ce chapitre traite de probabilités appliquées avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Maturité des compétences



Objectifs pédagogiques

- Comprendre le rôle de probabilités appliquées dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
distribution	Comment utiliser distribution pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
incertitude	Comment utiliser incertitude pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
loi normale	Comment utiliser loi normale pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
décision	Comment utiliser décision pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

distribution

distribution est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. distribution contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

incertitude


incertitude est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. incertitude contribue à rendre cette enquête plus rigoureuse.

loi normale

loi normale est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. loi normale contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**décision**

décision est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. décision contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Probabilités appliquées

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser probabilités appliquées pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à distribution. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à incertitude. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à loi normale. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à décision. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à distribution. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Tests statistiques

Ce chapitre traite de tests statistiques avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Objectifs pédagogiques

- Comprendre le rôle de tests statistiques dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
hypothèse	Comment utiliser hypothèse pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
p-value	Comment utiliser p-value pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
intervalle	Comment utiliser intervalle pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
erreur	Comment utiliser erreur pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

hypothèse

hypothèse est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. hypothèse contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning**p-value**


p-value est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. p-value contribue à rendre cette enquête plus rigoureuse.

intervalle

intervalle est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. intervalle contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle

Nuage de points : comprendre relation, dispersion et valeurs atypiques.

erreur

erreur est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. erreur contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Tests statistiques

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser tests statistiques pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à hypothèse. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à p-value. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à intervalle. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à erreur. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à hypothèse. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

DataFrame professionnel

Ce chapitre traite de dataframe professionnel avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Pipeline data science



Objectifs pédagogiques

- Comprendre le rôle de dataframe professionnel dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
lecture	Comment utiliser lecture pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
colonnes	Comment utiliser colonnes pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
types	Comment utiliser types pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
index	Comment utiliser index pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

lecture

lecture est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. lecture contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle

Nuage de points : comprendre relation, dispersion et valeurs atypiques.

colonnes

colonnes est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. colonnes contribue à rendre cette enquête plus rigoureuse.

types

types est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. types contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

index

index est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. index contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — DataFrame professionnel

```
import pandas as pd

df = pd.DataFrame({
    "client": ["A", "B", "C"],
    "montant": [120, None, 340],
    "ville": ["Kinshasa", "Goma", "Kinshasa"]
})

df["montant"] = df["montant"].fillna(df["montant"].median())
resume = df.groupby("ville")["montant"].mean()
print(resume)
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser dataframe professionnel pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.

- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à lecture. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à colonnes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à types. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à index. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à lecture. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Nettoyage des données

Ce chapitre traite de nettoyage des données avec une approche professionnelle. L’objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l’analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de nettoyage des données dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
valeurs manquantes	Comment utiliser valeurs manquantes pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
doublons	Comment utiliser doublons pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
formats	Comment utiliser formats pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
outliers	Comment utiliser outliers pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

valeurs manquantes

valeurs manquantes est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d’obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l’incertitude et traduire l’analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. valeurs manquantes contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences

Pandas



Stats



ML



DL



NLP



Vision

doublons


doublons est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. doublons contribue à rendre cette enquête plus rigoureuse.

formats

formats est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. formats contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning**outliers**

outliers est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. outliers contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Nettoyage des données

```
import pandas as pd

df = pd.DataFrame({
    "client": ["A", "B", "C"],
    "montant": [120, None, 340],
    "ville": ["Kinshasa", "Goma", "Kinshasa"]
})


df["montant"] = df["montant"].fillna(df["montant"].median())
resume = df.groupby("ville")["montant"].mean()
print(resume)
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser nettoyage des données pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.

- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à valeurs manquantes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à doublons. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à formats. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à outliers. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à valeurs manquantes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Transformation et agrégation

Ce chapitre traite de transformation et agrégation avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Maturité des compétences



Objectifs pédagogiques

- Comprendre le rôle de transformation et agrégation dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
groupby	Comment utiliser groupby pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
merge	Comment utiliser merge pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
pivot	Comment utiliser pivot pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
features	Comment utiliser features pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

groupby

groupby est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. groupby contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

merge

merge est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. merge contribue à rendre cette enquête plus rigoureuse.

pivot

pivot est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. pivot contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**features**

features est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. features contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Transformation et agrégation

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser transformation et agrégation pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à groupby. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à merge. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à pivot. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à features. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à groupby. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Qualité et gouvernance data

Ce chapitre traite de qualité et gouvernance data avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Objectifs pédagogiques

- Comprendre le rôle de qualité et gouvernance data dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
traçabilité	Comment utiliser traçabilité pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
dictionnaire	Comment utiliser dictionnaire pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
validation	Comment utiliser validation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
documentation	Comment utiliser documentation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

traçabilité

traçabilité est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. traçabilité contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning**dictionnaire**


dictionnaire est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. dictionnaire contribue à rendre cette enquête plus rigoureuse.

validation

validation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. validation contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle

Nuage de points : comprendre relation, dispersion et valeurs atypiques.

documentation

documentation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. documentation contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Qualité et gouvernance data

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser qualité et gouvernance data pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à traçabilité. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à dictionnaire. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à validation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à documentation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à traçabilité. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Matplotlib et Seaborn

Ce chapitre traite de matplotlib et seaborn avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Pipeline data science



Objectifs pédagogiques

- Comprendre le rôle de matplotlib et seaborn dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
histogramme	Comment utiliser histogramme pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
courbe	Comment utiliser courbe pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
boxplot	Comment utiliser boxplot pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
heatmap	Comment utiliser heatmap pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

histogramme

histogramme est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. histogramme contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle

Nuage de points : comprendre relation, dispersion et valeurs atypiques.

courbe

courbe est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. courbe contribue à rendre cette enquête plus rigoureuse.

boxplot

boxplot est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. boxplot contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

heatmap

heatmap est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. heatmap contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Matplotlib et Seaborn

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser matplotlib et seaborn pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à histogramme. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à courbe. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à boxplot. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à heatmap. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à histogramme. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Plotly et dashboards

Ce chapitre traite de plotly et dashboards avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de plotly et dashboards dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
interaction	Comment utiliser interaction pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
filtre	Comment utiliser filtre pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
KPI	Comment utiliser KPI pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
exploration	Comment utiliser exploration pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

interaction

interaction est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. interaction contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences**filtre**


filtre est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. filtre contribue à rendre cette enquête plus rigoureuse.

KPI

KPI est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. KPI contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning**exploration**

exploration est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. exploration contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Plotly et dashboards

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser plotly et dashboards pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à interaction. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à filtre. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à KPI. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à exploration. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à interaction. Définissez la question, les données, la méthode, la métrique et la conclusion.


Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Communication data

Ce chapitre traite de communication data avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.



Objectifs pédagogiques

- Comprendre le rôle de communication data dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
message	Comment utiliser message pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
contexte	Comment utiliser contexte pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
comparaison	Comment utiliser comparaison pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
limites	Comment utiliser limites pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

message

message est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. message contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

contexte


contexte est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. contexte contribue à rendre cette enquête plus rigoureuse.

comparaison

comparaison est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. comparaison contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**limites**

limites est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. limites contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Communication data

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser communication data pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à message. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à contexte. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à comparaison. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à limites. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à message. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Régression

Ce chapitre traite de régression avec une approche professionnelle. L’objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l’analyse en décision utile.

Pipeline data science



Objectifs pédagogiques

- Comprendre le rôle de régression dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
variables	Comment utiliser variables pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
erreur	Comment utiliser erreur pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
régularisation	Comment utiliser régularisation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
interprétation	Comment utiliser interprétation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.


Explication approfondie

variables

variables est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d’obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l’incertitude et traduire l’analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. variables contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

erreur

erreur est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. erreur contribue à rendre cette enquête plus rigoureuse.

régularisation

régularisation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. régularisation contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

interprétation

interprétation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. Interprétation contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Régression

```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
model = RandomForestClassifier(random_state=42)
model.fit(X_train, y_train)
print(classification_report(y_test, model.predict(X_test)))
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser régression pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à variables. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à erreur. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à régularisation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à interprétation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à variables. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Classification

Ce chapitre traite de classification avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de classification dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
classes	Comment utiliser classes pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
précision	Comment utiliser précision pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
rappel	Comment utiliser rappel pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
matrice de confusion	Comment utiliser matrice de confusion pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

classes

classes est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. classes contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences



Pandas



Stats



ML



DL



NLP



Vision

précision

précision est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.


Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. précision contribue à rendre cette enquête plus rigoureuse.

rappel

rappel est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. rappel contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning



matrice de confusion

matrice de confusion est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. matrice de confusion contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Classification

```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report


X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
model = RandomForestClassifier(random_state=42)
model.fit(X_train, y_train)
print(classification_report(y_test, model.predict(X_test)))
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser classification pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à classes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à précision. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à rappel. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à matrice de confusion. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à classes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Clustering

Ce chapitre traite de clustering avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Maturité des compétences



Pandas



Stats



ML



DL



NLP



Vision

Objectifs pédagogiques

- Comprendre le rôle de clustering dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
distance	Comment utiliser distance pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
segments	Comment utiliser segments pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
KMeans	Comment utiliser KMeans pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
profilage	Comment utiliser profilage pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

distance

distance est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. distance contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

segments


segments est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. segments contribue à rendre cette enquête plus rigoureuse.

KMeans

KMeans est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. KMeans contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**profilage**

profilage est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. profilage contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Clustering

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser clustering pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à distance. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à segments. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à KMeans. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à profilage. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à distance. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Évaluation des modèles

Ce chapitre traite de évaluation des modèles avec une approche professionnelle. L’objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l’analyse en décision utile.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Objectifs pédagogiques

- Comprendre le rôle de évaluation des modèles dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
train-test	Comment utiliser train-test pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
cross-validation	Comment utiliser cross-validation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
métriques	Comment utiliser métriques pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

surapprentissage	Comment utiliser surapprentissage pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
------------------	---	---


Explication approfondie

train-test

train-test est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d’obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l’incertitude et traduire l’analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. train-test contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning



cross-validation

cross-validation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.


Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. cross-validation contribue à rendre cette enquête plus rigoureuse.

métriques

métriques est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. métriques contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

surapprentissage

surapprentissage est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. Surapprentissage contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Évaluation des modèles

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser l'évaluation des modèles pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à train-test. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à cross-validation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à métriques. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à surapprentissage. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à train-test. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Feature engineering

Ce chapitre traite de feature engineering avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Schéma simplifié de deep learning



Objectifs pédagogiques

- Comprendre le rôle de feature engineering dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
encodage	Comment utiliser encodage pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
normalisation	Comment utiliser normalisation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
sélection	Comment utiliser sélection pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
pipeline	Comment utiliser pipeline pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

encodage

encodage est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. encodage contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**normalisation**

normalisation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. normalisation contribue à rendre cette enquête plus rigoureuse.

sélection

sélection est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. sélection contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences**pipeline**

pipeline est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. pipeline contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Feature engineering

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser feature engineering pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Maturité des compétences

Pandas



Stats



ML



DL



NLP



Vision

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à encodage. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à normalisation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à sélection. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à pipeline. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à encodage. Définissez la question, les données, la méthode, la métrique et la conclusion.


Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Réseaux neuronaux

Ce chapitre traite de réseaux neuronaux avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.



Objectifs pédagogiques

- Comprendre le rôle de réseaux neuronaux dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
neurone	Comment utiliser neurone pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
couche	Comment utiliser couche pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
activation	Comment utiliser activation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
perte	Comment utiliser perte pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.


Explication approfondie

neurone

neurone est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. neurone contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

couche

couche est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. couche contribue à rendre cette enquête plus rigoureuse.

activation

activation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. activation contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

perte

perte est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. Cette contribution contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Réseaux neuronaux

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser réseaux neuronaux pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à neurone. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à couche. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à activation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à perte. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à neurone. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

TensorFlow et Keras

Ce chapitre traite de tensorflow et keras avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de tensorflow et keras dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
modèle	Comment utiliser modèle pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
entraînement	Comment utiliser entraînement pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
callbacks	Comment utiliser callbacks pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
sauvegarde	Comment utiliser sauvegarde pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

modèle

modèle est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. modèle contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences

Pandas



Stats



ML



DL



NLP



Vision

entraînement


entraînement est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. entraînement contribue à rendre cette enquête plus rigoureuse.

callbacks

callbacks est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. callbacks contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning**sauvegarde**

sauvegarde est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. sauvegarde contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — TensorFlow et Keras

```
from tensorflow import keras

model = keras.Sequential([
    keras.layers.Dense(64, activation="relu", input_shape=(10,)),
    keras.layers.Dense(1, activation="sigmoid")
])


model.compile(optimizer="adam", loss="binary_crossentropy", metrics=["accuracy"])
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser tensorflow et keras pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Réseau neuronal : couches, poids, propagation et décision.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à modèle. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à entraînement. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à callbacks. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à sauvegarde. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à modèle. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

PyTorch

Ce chapitre traite de pytorch avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Maturité des compétences



Objectifs pédagogiques

- Comprendre le rôle de pytorch dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
tensor	Comment utiliser tensor pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
autograd	Comment utiliser autograd pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
module	Comment utiliser module pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
training loop	Comment utiliser training loop pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

tensor

tensor est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. tensor contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

autograd


autograd est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. autograd contribue à rendre cette enquête plus rigoureuse.

module

module est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. module contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**training loop**

training loop est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. training loop contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — PyTorch

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser pytorch pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à tensor. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à autograd. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à module. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à training loop. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à tensor. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

MLOps pour deep learning

Ce chapitre traite de mlops pour deep learning avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Objectifs pédagogiques

- Comprendre le rôle de mlops pour deep learning dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
versioning	Comment utiliser versioning pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
monitoring	Comment utiliser monitoring pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
drift	Comment utiliser drift pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
déploiement	Comment utiliser déploiement pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.


Explication approfondie

versioning

versioning est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. versioning contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning

**monitoring**

monitoring est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.


Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. monitoring contribue à rendre cette enquête plus rigoureuse.

drift

drift est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. drift contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

déploiement

déploiement est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. déploiement contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — MLOps pour deep learning

```
from tensorflow import keras

model = keras.Sequential([
    keras.layers.Dense(64, activation="relu", input_shape=(10,)),
    keras.layers.Dense(1, activation="sigmoid")
])


model.compile(optimizer="adam", loss="binary_crossentropy", metrics=["accuracy"])
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser mlops pour deep learning pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à versioning. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à monitoring. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à drift. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à déploiement. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à versioning. Définissez la question, les données, la méthode, la métrique et la conclusion.


Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Traitement du texte

Ce chapitre traite de traitement du texte avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.



Objectifs pédagogiques

- Comprendre le rôle de traitement du texte dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
tokenisation	Comment utiliser tokenisation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
nettoyage	Comment utiliser nettoyage pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
lemmatisation	Comment utiliser lemmatisation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
n-grammes	Comment utiliser n-grammes pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.


Explication approfondie

tokenisation

tokenisation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. tokenisation contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

nettoyage

nettoyage est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. nettoyage contribue à rendre cette enquête plus rigoureuse.

lemmatisation

lemmatisation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. lemmatisation contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

n-grammes

n-grammes est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. n-grammes contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Traitement du texte

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression

texts = ["paiement reçu", "erreur compte", "colis livré"]
labels = ["finance", "support", "logistique"]

vectorizer = TfidfVectorizer()
X = vectorizer.fit_transform(texts)
model = LogisticRegression().fit(X, labels)
print(model.predict(vectorizer.transform(["problème de paiement"])))
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser traitement du texte pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.

- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à tokenisation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à nettoyage. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à lemmatisation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à n-grammes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à tokenisation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Classification de texte

Ce chapitre traite de classification de texte avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de classification de texte dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
sentiment	Comment utiliser sentiment pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
spam	Comment utiliser spam pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
support client	Comment utiliser support client pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
évaluation	Comment utiliser évaluation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

sentiment

sentiment est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. sentiment contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences



Pandas



Stats



ML



DL



NLP



Vision

spam

spam est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.


Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. spam contribue à rendre cette enquête plus rigoureuse.

support client

support client est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. support client contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning

**évaluation**

évaluation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. évaluation contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Classification de texte

```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report


X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
model = RandomForestClassifier(random_state=42)
model.fit(X_train, y_train)
print(classification_report(y_test, model.predict(X_test)))
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser classification de texte pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à sentiment. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à spam. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à support client. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à évaluation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à sentiment. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Embeddings et transformers

Ce chapitre traite de embeddings et transformers avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Maturité des compétences



Objectifs pédagogiques

- Comprendre le rôle de embeddings et transformers dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
vecteurs	Comment utiliser vecteurs pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
attention	Comment utiliser attention pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
fine-tuning	Comment utiliser fine-tuning pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
limites	Comment utiliser limites pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

vecteurs

vecteurs est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. vecteurs contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

attention


attention est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. attention contribue à rendre cette enquête plus rigoureuse.

fine-tuning

fine-tuning est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. fine-tuning contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**limites**

limites est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. limites contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Embeddings et transformers

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser embeddings et transformers pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à vecteurs. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à attention. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à fine-tuning. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à limites. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à vecteurs. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Applications africaines du NLP

Ce chapitre traite de applications africaines du nlp avec une approche professionnelle. L’objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l’analyse en décision utile.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Objectifs pédagogiques

- Comprendre le rôle de applications africaines du nlp dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
langues locales	Comment utiliser langues locales pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
administration	Comment utiliser administration pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
éducation	Comment utiliser éducation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
service client	Comment utiliser service client pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

langues locales

langues locales est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d’obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l’incertitude et traduire l’analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. langues locales contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning**administration**


administration est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. administration contribue à rendre cette enquête plus rigoureuse.

éducation

éducation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. éducation contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle

Nuage de points : comprendre relation, dispersion et valeurs atypiques.

service client

service client est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. service client contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Applications africaines du NLP

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression

texts = ["paiement reçu", "erreur compte", "colis livré"]
labels = ["finance", "support", "logistique"]


vectorizer = TfidfVectorizer()
X = vectorizer.fit_transform(texts)
model = LogisticRegression().fit(X, labels)
print(model.predict(vectorizer.transform(["problème de paiement"])))
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser applications africaines du nlp pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.

- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à langues locales. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à administration. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à éducation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à service client. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à langues locales. Définissez la question, les données, la méthode, la métrique et la conclusion.


Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Bases de l'image numérique

Ce chapitre traite de bases de l'image numérique avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.



Objectifs pédagogiques

- Comprendre le rôle de bases de l'image numérique dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
pixels	Comment utiliser pixels pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
canaux	Comment utiliser canaux pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
filtres	Comment utiliser filtres pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
prétraitement	Comment utiliser prétraitement pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.


Explication approfondie

pixels

pixels est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. pixels contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

canaux

canaux est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. canaux contribue à rendre cette enquête plus rigoureuse.

filtres

filtres est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. filtres contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

prétraitement

prétraitement est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. prétraitement contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Bases de l'image numérique

```
from PIL import Image
import numpy as np

image = Image.open("photo.jpg").resize((224, 224))
array = np.array(image) / 255.0
print(array.shape) # hauteur, largeur, canaux
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser bases de l'image numérique pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à pixels. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à canaux. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à filtres. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à prétraitement. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à pixels. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Classification d'images

Ce chapitre traite de classification d'images avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de classification d'images dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
CNN	Comment utiliser CNN pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
augmentation	Comment utiliser augmentation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
validation	Comment utiliser validation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
erreurs	Comment utiliser erreurs pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

CNN

CNN est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. CNN contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences



Pandas



Stats



ML



DL



NLP



Vision

augmentation

augmentation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.


Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. augmentation contribue à rendre cette enquête plus rigoureuse.

validation

validation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. validation contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning



erreurs

erreurs est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. erreurs contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Classification d'images

```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report


X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
model = RandomForestClassifier(random_state=42)
model.fit(X_train, y_train)
print(classification_report(y_test, model.predict(X_test)))
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser classification d'images pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à CNN. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à augmentation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à validation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à erreurs. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à CNN. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Détection et segmentation

Ce chapitre traite de détection et segmentation avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Maturité des compétences



Objectifs pédagogiques

- Comprendre le rôle de détection et segmentation dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
objets	Comment utiliser objets pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
masques	Comment utiliser masques pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
annotation	Comment utiliser annotation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
métriques	Comment utiliser métriques pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

objets

objets est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. objets contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

masques


masques est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. masques contribue à rendre cette enquête plus rigoureuse.

annotation

annotation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. annotation contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**métriques**

métriques est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. métriques contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Détection et segmentation

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser détection et segmentation pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à objets. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à masques. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à annotation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à métriques. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à objets. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Cas santé, sécurité et agriculture

Ce chapitre traite de cas santé, sécurité et agriculture avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Objectifs pédagogiques

- Comprendre le rôle de cas santé, sécurité et agriculture dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
imagerie	Comment utiliser imagerie pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
surveillance	Comment utiliser surveillance pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
cultures	Comment utiliser cultures pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
éthique	Comment utiliser éthique pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

imagerie

imagerie est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. imagerie contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning**surveillance**


surveillance est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. surveillance contribue à rendre cette enquête plus rigoureuse.

cultures

cultures est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. cultures contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle

Nuage de points : comprendre relation, dispersion et valeurs atypiques.

éthique

éthique est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. éthique contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Cas santé, sécurité et agriculture

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser cas santé, sécurité et agriculture pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à imagerie. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à surveillance. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à cultures. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à éthique. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à imagerie. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Scoring bancaire

Ce chapitre traite de scoring bancaire avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Pipeline data science



Objectifs pédagogiques

- Comprendre le rôle de scoring bancaire dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
risque	Comment utiliser risque pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
features	Comment utiliser features pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
modèle	Comment utiliser modèle pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
explicabilité	Comment utiliser explicabilité pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.


Explication approfondie

risque

risque est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. risque contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

features

features est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. features contribue à rendre cette enquête plus rigoureuse.

modèle

modèle est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. modèle contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

explicabilité

explicabilité est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. explicabilité contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Scoring bancaire

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser scoring bancaire pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à risque. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à features. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à modèle. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à explicabilité. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à risque. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Prévision santé publique

Ce chapitre traite de prévision santé publique avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de prévision santé publique dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
séries	Comment utiliser séries pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
épidémiologie	Comment utiliser épidémiologie pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
alertes	Comment utiliser alertes pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

tableau de bord	Comment utiliser tableau de bord pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
-----------------	--	---

Explication approfondie

séries

séries est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. séries contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences

Pandas



Stats



ML



DL



NLP



Vision

épidémiologie

épidémiologie est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. épidémiologie contribue à rendre cette enquête plus rigoureuse.

alertes

alertes est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. alertes contribue à rendre cette enquête plus rigoureuse.


Schéma simplifié de deep learning**tableau de bord**

tableau de bord est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. tableau de bord contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Prévision santé publique

```
from PIL import Image
import numpy as np


image = Image.open("photo.jpg").resize((224, 224))
array = np.array(image) / 255.0
print(array.shape) # hauteur, largeur, canaux
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser prévision santé publique pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à séries. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à épidémiologie. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à alertes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à tableau de bord. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à séries. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Recommandation e-commerce

Ce chapitre traite de recommandation e-commerce avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Maturité des compétences



Objectifs pédagogiques

- Comprendre le rôle de recommandation e-commerce dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
historique	Comment utiliser historique pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
similarité	Comment utiliser similarité pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
ranking	Comment utiliser ranking pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
évaluation	Comment utiliser évaluation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

historique

historique est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. historique contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

similarité

similarité est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. similarité contribue à rendre cette enquête plus rigoureuse.

ranking

ranking est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. ranking contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**évaluation**

évaluation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. évaluation contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Recommandation e-commerce

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser recommandation e-commerce pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à historique. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à similarité. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à ranking. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à évaluation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à historique. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Assistant IA métier

Ce chapitre traite de assistant ia métier avec une approche professionnelle. L’objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l’analyse en décision utile.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Objectifs pédagogiques

- Comprendre le rôle de assistant ia métier dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
données	Comment utiliser données pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
contexte	Comment utiliser contexte pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
réponse	Comment utiliser réponse pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
sécurité	Comment utiliser sécurité pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.


Explication approfondie

données

données est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d’obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l’incertitude et traduire l’analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. données contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning



contexte

contexte est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.


Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. contexte contribue à rendre cette enquête plus rigoureuse.

réponse

réponse est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. réponse contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

sécurité

sécurité est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. sécurité contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Assistant IA métier

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser assistant ia métier pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à données. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à contexte. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à réponse. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à sécurité. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à données. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Vision intelligente

Ce chapitre traite de vision intelligente avec une approche professionnelle. L’objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l’analyse en décision utile.

Schéma simplifié de deep learning



Objectifs pédagogiques

- Comprendre le rôle de vision intelligente dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
caméra	Comment utiliser caméra pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
classification	Comment utiliser classification pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
alerte	Comment utiliser alerte pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
audit	Comment utiliser audit pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

caméra

caméra est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d’obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l’incertitude et traduire l’analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. caméra contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**classification**

classification est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. classification contribue à rendre cette enquête plus rigoureuse.

alerte

alerte est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. alerte contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences**audit**

audit est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. audit contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Vision intelligente

```
from PIL import Image
import numpy as np

image = Image.open("photo.jpg").resize((224, 224))
array = np.array(image) / 255.0
print(array.shape) # hauteur, largeur, canaux
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser vision intelligente pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Maturité des compétences

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à caméra. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à classification. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à alerte. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à audit. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à caméra. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Banque d'exercices

Ce chapitre traite de banque d'exercices avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Pipeline data science



Objectifs pédagogiques

- Comprendre le rôle de banque d'exercices dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.


Notion	Question data	Livrable attendu
statistiques	Comment utiliser statistiques pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
Pandas	Comment utiliser Pandas pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
ML	Comment utiliser ML pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
IA	Comment utiliser IA pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

statistiques

statistiques est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. statistiques contribue à rendre cette enquête plus rigoureuse.

Analyse exploratoire visuelle

Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Pandas

Pandas est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. Pandas contribue à rendre cette enquête plus rigoureuse.

ML

ML est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. ML contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

IA

IA est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. IA contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Banque d'exercices

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser banque d'exercices pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.

- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à statistiques. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à Pandas. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à ML. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à IA. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à statistiques. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Examens blancs

Ce chapitre traite de examens blancs avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Objectifs pédagogiques

- Comprendre le rôle de examens blancs dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
questions	Comment utiliser questions pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
cas	Comment utiliser cas pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
projet	Comment utiliser projet pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
soutenance	Comment utiliser soutenance pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

questions

questions est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. questions contribue à rendre cette enquête plus rigoureuse.

Maturité des compétences

Pandas



Stats



ML



DL



NLP



Vision

cas


cas est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. cas contribue à rendre cette enquête plus rigoureuse.

projet

projet est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. projet contribue à rendre cette enquête plus rigoureuse.

Schéma simplifié de deep learning**soutenance**

soutenance est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. soutenance contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Examens blancs

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()


print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser examens blancs pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Schéma simplifié de deep learning



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à questions. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à cas. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à projet. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à soutenance. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à questions. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.


Quiz de validation

- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Glossaire et feuilles de route

Ce chapitre traite de glossaire et feuilles de route avec une approche professionnelle. L'objectif est de savoir analyser le problème, préparer les données, choisir une méthode, évaluer le résultat, expliquer les limites et transformer l'analyse en décision utile.

Maturité des compétences



Objectifs pédagogiques

- Comprendre le rôle de glossaire et feuilles de route dans un projet data réel.
- Choisir les bons outils selon la question métier.
- Évaluer les résultats avec des métriques adaptées.
- Identifier les biais, limites et risques de mauvaise interprétation.
- Produire un livrable clair : notebook, rapport, dashboard ou API modèle.

Notion	Question data	Livrable attendu
termes	Comment utiliser termes pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
références	Comment utiliser références pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
progression	Comment utiliser progression pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.
spécialisation	Comment utiliser spécialisation pour améliorer une décision ?	Analyse claire, code reproductible, métrique et interprétation.

Explication approfondie

termes

termes est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. termes contribue à rendre cette enquête plus rigoureuse.

Matrice de corrélation / performance

Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

références


références est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. références contribue à rendre cette enquête plus rigoureuse.

progression

progression est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. progression contribue à rendre cette enquête plus rigoureuse.

Pipeline data science**spécialisation**

spécialisation est une brique importante du travail data. Dans un contexte professionnel, il ne suffit pas d'obtenir un résultat technique : il faut comprendre la donnée, vérifier sa qualité, expliquer l'incertitude et traduire l'analyse en action. Un modèle performant mais incompris peut devenir dangereux ; un modèle modeste mais bien expliqué peut créer une vraie valeur.

Analogie : un data scientist ressemble à un enquêteur. Il collecte les indices, vérifie les sources, élimine les fausses pistes, construit une hypothèse, puis présente une conclusion avec prudence. spécialisation contribue à rendre cette enquête plus rigoureuse.

Exemple de code

Code — Glossaire et feuilles de route

```
import numpy as np

values = np.array([12, 15, 18, 21, 100])
mean = values.mean()
median = np.median(values)
std = values.std()

print({"moyenne": mean, "médiane": median, "écart_type": std})
```

Le code présenté est volontairement compact afin de montrer la logique essentielle. Dans un projet professionnel, il doit être complété par des tests, une gestion des erreurs, une documentation des données et une évaluation transparente.

Cas pratique professionnel

Une entreprise peut utiliser glossaire et feuilles de route pour réduire les coûts, détecter des tendances, améliorer le service client, prévoir la demande, sécuriser les décisions ou automatiser des tâches complexes. Le succès dépend moins du modèle choisi que de la qualité du problème posé et de la fiabilité des données.

Pipeline data science



Bonnes pratiques

- Définir la question métier avant d'ouvrir le notebook.
- Séparer données brutes, données nettoyées et résultats.
- Comparer plusieurs méthodes avec la même métrique.
- Documenter les biais, les hypothèses et les limites.
- Ne jamais déployer un modèle sans monitoring.
- Expliquer les résultats dans un langage compréhensible par les décideurs.

Pièges à éviter

- Confondre corrélation et causalité.
- Optimiser une métrique sans vérifier l'impact métier.
- Entraîner un modèle sur des données non représentatives.
- Ignorer les valeurs manquantes ou les doublons.
- Déployer une IA sans contrôle humain et sans audit.

Exercices corrigés

Exercice 1 : construisez une mini analyse liée à termes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 1 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 2 : construisez une mini analyse liée à références. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 2 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 3 : construisez une mini analyse liée à progression. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 3 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 4 : construisez une mini analyse liée à spécialisation. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 4 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Exercice 5 : construisez une mini analyse liée à termes. Définissez la question, les données, la méthode, la métrique et la conclusion.

Corrigé 5 : une réponse solide contient une hypothèse claire, un nettoyage minimal, une visualisation, une métrique et une conclusion prudente. Le résultat doit mentionner au moins une limite.

Quiz de validation


- Quelle question métier ce chapitre permet-il de traiter ?
- Quelle métrique choisir et pourquoi ?
- Quel biais peut influencer le résultat ?
- Comment expliquer le résultat à un non-technicien ?
- Quelle étape faut-il surveiller après déploiement ?

Banque de 450 exercices Data Science et IA

Cette banque entraîne les apprenants à pratiquer toute la chaîne data : statistiques, Pandas, visualisation, machine learning, deep learning, NLP, computer vision, évaluation et projets professionnels.

Statistiques

Pipeline data science



Exercice 1 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 2 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 3 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 4 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 5 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 6 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 7 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 8 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 9 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 10 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 11 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 12 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 13 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 14 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 15 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 16 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 17 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 45 : réalisez une tâche liée à Statistiques. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 59 : réalisez une tâche liée à Pandas. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 83 : réalisez une tâche liée à Pandas. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 126 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 127 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 128 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 129 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 130 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 131 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 132 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 133 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 134 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 135 : réalisez une tâche liée à Visualisation. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Régression

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Exercice 136 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 137 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 138 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 139 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 140 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 141 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 142 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 143 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 144 : réalisez une tâche liée à Régression. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 210 : réalisez une tâche liée à Classification. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 225 : réalisez une tâche liée à Classification. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 270 : réalisez une tâche liée à Clustering. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 296 : réalisez une tâche liée à Deep Learning. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 315 : réalisez une tâche liée à Deep Learning. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 360 : réalisez une tâche liée à NLP. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 403 : réalisez une tâche liée à Computer Vision. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 405 : réalisez une tâche liée à Computer Vision. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Schéma simplifié de deep learning

The diagram illustrates a simplified deep learning architecture with four layers of nodes. The first layer (input) has 3 green nodes. The second layer has 4 blue nodes. The third layer has 5 orange nodes. The fourth layer (output) has 2 purple nodes. Every node in one layer is connected to every node in the next layer by a thin grey line, representing a fully connected structure. Below the diagram, the text reads: 'Réseau neuronal : couches, poids, propagation et décision.'

Exercice 421 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 423 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 425 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 427 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 429 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 431 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 433 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 435 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 437 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 439 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 441 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 443 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 445 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 446 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 447 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 448 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 449 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Exercice 450 : réalisez une tâche liée à MLOps. Décrivez la question, le jeu de données, la méthode, une visualisation, une métrique, une limite et une recommandation. Corrigé attendu : démarche reproductible, code clair, interprétation et prudence.

Examens blancs

Examen blanc 1

- Partie A : statistiques et interprétation.
- Partie B : nettoyage avec Pandas.
- Partie C : visualisation et storytelling.
- Partie D : modèle machine learning et métriques.
- Partie E : projet IA avec rapport professionnel.

Examen blanc 2

- Partie A : statistiques et interprétation.
- Partie B : nettoyage avec Pandas.
- Partie C : visualisation et storytelling.
- Partie D : modèle machine learning et métriques.
- Partie E : projet IA avec rapport professionnel.

Examen blanc 3

- Partie A : statistiques et interprétation.
- Partie B : nettoyage avec Pandas.
- Partie C : visualisation et storytelling.
- Partie D : modèle machine learning et métriques.
- Partie E : projet IA avec rapport professionnel.

Examen blanc 4

- Partie A : statistiques et interprétation.
- Partie B : nettoyage avec Pandas.
- Partie C : visualisation et storytelling.
- Partie D : modèle machine learning et métriques.
- Partie E : projet IA avec rapport professionnel.

Examen blanc 5

- Partie A : statistiques et interprétation.
- Partie B : nettoyage avec Pandas.

- Partie C : visualisation et storytelling.
- Partie D : modèle machine learning et métriques.
- Partie E : projet IA avec rapport professionnel.

Examen blanc 6

- Partie A : statistiques et interprétation.
- Partie B : nettoyage avec Pandas.
- Partie C : visualisation et storytelling.
- Partie D : modèle machine learning et métriques.
- Partie E : projet IA avec rapport professionnel.

Glossaire Data Science et IA

Terme	Définition
Feature	Variable utilisée comme entrée d'un modèle.
Label	Valeur cible à prédire ou expliquer.
Overfitting	Modèle trop adapté aux données d'entraînement.
Cross-validation	Méthode d'évaluation plus robuste par découpage multiple.
Embedding	Représentation vectorielle d'un texte, image ou objet.
CNN	Réseau neuronal spécialisé dans les images.
Transformer	Architecture moderne fondée sur l'attention, utile en NLP et vision.
Drift	Changement des données ou comportements après déploiement.

Feuille de route Data Scientist et ingénieur IA

- Maîtriser Python, statistiques, Pandas et visualisation.
- Comprendre les métriques et la validation des modèles.
- Construire des projets ML, NLP et computer vision.
- Apprendre le déploiement, le monitoring et le MLOps.
- Documenter les biais, limites, risques et impacts métier.
- Développer une communication claire avec les décideurs.

Contact professionnel

Charmant Nyungu — Consultant en innovation technologique, transformation numérique, cybersécurité, intelligence artificielle, développement logiciel et stratégie digitale.

- www.charmantnyungu.com
- consultant@charmantnyungu.com
- +243 835 137 837

Fiche pratique Data & IA 172

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Maturité des compétences



Pandas



Stats



ML



DL



NLP



Vision

Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 173

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.


Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 174

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Schéma simplifié de deep learning



Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 175

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Pipeline data science



Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.


Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 176

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```


Fiche pratique Data & IA 177

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Maturité des compétences



Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 178

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.


Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 179

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Schéma simplifié de deep learning



Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 180

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Pipeline data science



Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.


Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 181

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Analyse exploratoire visuelle



Nuage de points : comprendre relation, dispersion et valeurs atypiques.

Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 182

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Maturité des compétences



Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 183

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Matrice de corrélation / performance



Carte thermique : comparer variables, corrélations, segments ou erreurs modèle.

Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.


Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```

Fiche pratique Data & IA 184

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Schéma simplifié de deep learning



Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```


Fiche pratique Data & IA 185

Cette fiche sert de révision guidée. Elle demande à l'apprenant de choisir une question métier, un jeu de données, une méthode, une métrique, une visualisation et une limite. La qualité du raisonnement compte autant que le score obtenu.

Pipeline data science



Étape	Résultat attendu
Question	Une question métier précise et mesurable.
Données	Sources, qualité, dictionnaire et limites.
Méthode	Statistique, modèle ou visualisation adaptée.
Évaluation	Métrique, interprétation et prudence.

Gabarit de diagnostic data

```
def summarize_dataset(df):
    return {
        "rows": len(df),
        "columns": list(df.columns),
        "missing": df.isna().sum().to_dict()
    }
```